

PROJETO APLICADO III

Universidade Presbiteriana Mackenzie

Sistema de Recomendação de Músicas Baseado em Atributos Acústicos com Machine Learning

Uma Análise do Spotify Tracks Dataset

Integrantes:

- *Giovanna da Silva Santos*
- *Julia Petra Teixeira Chaves*
- *Larissa Jacinto Bispo Christofoletti*

Etapa 2 – Resultados Preliminares (PoC), Ajuste do Pipeline e Referencial Teórico

São Paulo · 2026

Índice

1. Introdução
 - 1.1 Contexto do Trabalho
 - 1.2 Motivação
 - 1.3 Justificativa
2. Objetivos
 - 2.1 Objetivo Geral
 - 2.2 Objetivos Específicos
3. Descrição do Dataset
 - 3.1 Fonte e Licença
 - 3.2 Visão Geral
 - 3.3 Variáveis Utilizadas
4. Metodologia e Atividades da Etapa 2
 - 4.1 Definição das Bibliotecas Python
 - 4.2 Análise Exploratória dos Dados (EDA)
 - 4.3 Tratamento e Preparação da Base
 - 4.4 Técnica de Recomendação
 - 4.5 Prova de Conceito (PoC)
 - 4.6 Avaliação de Desempenho
5. Referencial Teórico
6. Apresentação dos Resultados
7. Cronograma do Projeto
8. Repositório no GitHub
9. Referências

1. Introdução

1.1 Contexto do Trabalho

O crescimento exponencial do streaming musical transformou radicalmente a forma como a indústria fonográfica organiza, distribui e recomenda conteúdo. Plataformas como o Spotify acumulam acervos com dezenas de milhões de faixas, o que torna a recomendação personalizada de músicas um problema central de engenharia e ciência de dados.

A API do Spotify disponibiliza atributos acústicos e rítmicos calculados automaticamente para cada faixa, como energia, dançabilidade, valência e BPM, que descrevem numericamente o perfil sonoro de uma música. Este projeto propõe utilizar esses metadados para desenvolver um motor de recomendação capaz de sugerir faixas semelhantes com base exclusivamente em suas características acústicas, dispensando a análise de áudio bruto.

1.2 Motivação

A motivação central do projeto está na intersecção entre a explosão de dados musicais digitais e o avanço dos algoritmos de aprendizado de máquina para filtragem e recomendação de conteúdo. Recomendar faixas com precisão é um desafio complexo, pois as preferências musicais dependem de nuances e combinações subjetivas de atributos sonoros.

Além disso, o desenvolvimento de uma interface gráfica interativa agrega valor prático ao projeto: o usuário pode simular o perfil sonoro desejado e receber recomendações personalizadas em tempo real.

1.3 Justificativa

O projeto se justifica pela relevância acadêmica e comercial dos sistemas de recomendação de áudio. Recomendação, curadoria de playlists e retenção de usuários em plataformas de streaming dependem diretamente de um motor de busca por similaridade preciso e eficiente.

O Spotify Tracks Dataset viabiliza o experimento por reunir aproximadamente 114.000 faixas com 20 atributos cada, o que confere robustez estatística à construção dos vetores de características (*feature vectors*) e permite gerar recomendações alinhadas ao perfil sonoro desejado.

2. Objetivos

2.1 Objetivo Geral

Desenvolver um pipeline preditivo e um motor de recomendação *end-to-end* capazes de gerar sugestões personalizadas de músicas do Spotify a partir de atributos acústicos, integrando o modelo a uma interface gráfica interativa desktop.

2.2 Objetivos Específicos

Para cumprir o escopo da Etapa 2, foram definidos os seguintes objetivos específicos, detalhados na Seção 4:

- Definir as bibliotecas Python que compõem o ecossistema de desenvolvimento;
- Analisar de forma exploratória a base de dados (EDA);
- Tratar e preparar a base para o treinamento;
- Definir a técnica de recomendação;
- Treinar um modelo inicial como prova de conceito (PoC);
- Definir a forma de avaliação de desempenho do modelo;
- Descrever o referencial teórico que sustenta as escolhas do projeto.

3. Descrição do Dataset

3.1 Fonte e Licença

O dataset utilizado é o **Spotify Tracks Dataset**, disponibilizado no Kaggle por Maharshi Pandya (kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset) sob licença CC0 (Domínio Público). Os dados foram extraídos via API oficial do Spotify e consolidados em um único arquivo CSV.

3.2 Visão Geral

- **Instâncias:** aproximadamente 114.000 faixas
- **Atributos:** 20 por faixa, entre identificadores textuais e métricas acústicas numéricas calculadas pelo Spotify
- **Formato:** CSV (valores separados por vírgula)
- **Licença:** CC0 – Domínio Público

3.3 Variáveis Utilizadas

Os atributos numéricos de áudio compõem o vetor de características usado pelo modelo para calcular a similaridade entre faixas e entregar recomendações em tempo real.

Variável	Tipo	Descrição
popularity	Inteiro (0–100)	Popularidade da faixa no momento da coleta
danceability	Float (0–1)	Adequação da faixa para dança
energy	Float (0–1)	Intensidade e atividade percebida da faixa
key	Inteiro (0–11)	Tom musical (0 = Dó, 1 = Dó#, ...)
loudness	Float (dB)	Volume médio em decibéis
mode	Inteiro (0/1)	Modalidade tonal: 0 = menor, 1 = maior
speechiness	Float (0–1)	Presença de palavras faladas
acousticness	Float (0–1)	Confiança de que a faixa é acústica
instrumentalness	Float (0–1)	Probabilidade de a faixa não ter vocais
liveness	Float (0–1)	Probabilidade de a gravação ser ao vivo
valence	Float (0–1)	Positividade musical transmitida pela faixa
tempo	Float (BPM)	Andamento estimado em batidas por minuto

4. Metodologia e Atividades da Etapa 2

4.1 Definição das Bibliotecas Python

Foram selecionadas e configuradas as bibliotecas abaixo, organizadas por finalidade:

- **Manipulação e processamento de dados:** *pandas* (leitura, manipulação tabular e filtragem) e *numpy* (operações vetoriais e cálculos matriciais de alta performance).
- **Análise exploratória e visualização:** *matplotlib* (gráficos estáticos e de radar) e *seaborn* (mapas de calor de correlação e gráficos de distribuição).
- **Machine Learning e recomendação:** *scikit-learn* (pré-processamento, padronização com StandardScaler/MinMaxScaler, PCA, agrupamento K-Means e rotinas de vizinhos mais próximos com NearestNeighbors) e *scipy* (métricas de distância vetorial, como cosine e euclidean).
- **Interface gráfica interativa:** *customtkinter* (painel desktop com sliders interativos e botões de simulação).

4.2 Análise Exploratória dos Dados (EDA)

- Inspeção da estrutura do dataset (~114.000 faixas e 20 atributos);
- Estatística descritiva (média, mediana, desvio padrão e limites) para compreender a distribuição das variáveis acústicas;
- Matriz de correlação (Pearson/Spearman) para mapear o comportamento conjunto das variáveis, por exemplo a alta correlação entre *energy* e *loudness* e a correlação inversa entre *energy* e *acousticness*;
- Mapeamento das distribuições e verificação de duplicatas decorrentes de reedições de álbuns.

4.3 Tratamento e Preparação da Base

1. **Duplicatas:** remoção de registros duplicados com base na combinação única de *track_name* e *artists*, mantendo a versão de maior *popularity*.
2. **Valores nulos:** a taxa é muito baixa (< 0,1%), concentrada em registros com metadados incompletos; o tratamento é a remoção dos registros incompletos.
3. **Outliers:** corte por percentis em *loudness* e *duration_ms*, para evitar distorções nos cálculos de distância.
4. **Escalamento:** padronização com MinMaxScaler ou StandardScaler, de modo que todas as métricas sonoras fiquem na mesma escala (por exemplo, [0, 1]) e atributos de maior magnitude numérica não dominem a métrica de distância.
5. **Vetor de características:** isolamento do vetor final $V = [\text{danceability}, \text{energy}, \text{loudness}, \text{speechiness}, \text{acousticness}, \text{instrumentalness}, \text{liveness}, \text{valence}, \text{tempo}, \text{popularity}]$.

4.4 Técnica de Recomendação

Adotou-se a **Filtragem Baseada em Conteúdo** (*Content-Based Filtering*), combinando a **Similaridade de Cosseno** com o algoritmo **k-Nearest Neighbors (k-NN)**. Cada música é representada como um vetor n -dimensional, e a similaridade entre dois vetores A e B é dada por:

$$\text{Similaridade}(A, B) = (A \cdot B) / (\|A\| \cdot \|B\|) = \sum A_i B_i / (\sqrt{\sum A_i^2} \cdot \sqrt{\sum B_i^2}), \text{ com } i = 1 \text{ até } n$$

Complementarmente, o algoritmo **K-Means** é aplicado para criar clusters sonoros e acelerar a busca de vizinhos próximos em grandes volumes de dados.

4.5 Prova de Conceito (PoC)

A PoC consistiu em:

- Configurar o pipeline básico de dados e pré-processamento;
- Instanciar e ajustar o modelo de vizinhos mais próximos: `NearestNeighbors(n_neighbors=10, metric='cosine', algorithm='brute');`
- Executar testes com faixas de referência e com entrada manual de vetores simulados por sliders, verificando se a lista de 10 faixas recomendadas mantém coerência acústica com a entrada.

4.6 Avaliação de Desempenho

Métrica	O que mede
Erro Médio de Proximidade Acústica (<i>Cosine Distance Mean</i>)	Distância vetorial média entre o item de entrada e as faixas recomendadas
Consistência Interna (<i>Intra-List Similarity – ILS</i>)	Grau de coesão e harmonia do estilo sonoro da lista recomendada
Cobertura do Catálogo (<i>Coverage</i>)	Percentual do catálogo recomendado em múltiplos cenários de teste
Diversidade (<i>Diversity</i>)	Variabilidade dos artistas sugeridos, para evitar estagnação

5. Referencial Teórico

A fundamentação teórica sustenta o desenvolvimento do sistema e posiciona o trabalho na área de Ciência de Dados e Recuperação de Informação Musical (*Music Information Retrieval – MIR*).

Sistemas de recomendação baseados em conteúdo (CBF). Segundo Lops et al. (2011), a Filtragem Baseada em Conteúdo sugere itens com propriedades semelhantes às de itens previamente apreciados pelo usuário. Na música, essa abordagem contorna o problema de *cold start* (falta de dados de interação para faixas novas), pois calcula a relação entre as músicas usando apenas os atributos do próprio áudio.

Representação e extração de atributos em MIR. Schedl et al. (2014) mostram que metadados numéricos de baixo custo computacional, extraídos de APIs de áudio (como *danceability*, *energy*, *valence* e *loudness*), traduzem de forma satisfatória dimensões perceptivas e emocionais do ouvinte. Convertidos em vetores numéricos normalizados, esses atributos permitem cálculos geométricos e de vizinhança espacial.

Métricas de similaridade e algoritmos de vizinhança (*k*-NN). O uso da similaridade de cosseno em espaços vetoriais multidimensionais é amplamente validado na literatura (Ricci et al., 2015). A métrica avalia o ângulo entre os vetores, o que a torna preferível à distância euclidiana em dados de muitas dimensões, pois considera a proporção e a orientação do perfil sonoro, e não sua magnitude bruta.

6. Apresentação dos Resultados

Os resultados da PoC serão apresentados ao professor orientador para demonstrar o funcionamento do pipeline e avaliar o alinhamento das recomendações geradas. A partir dos feedbacks recebidos, o grupo ajustará o pipeline e entregará a versão atualizada deste documento, consolidando o Referencial Teórico e os testes preliminares de recomendação.

7. Cronograma do Projeto

Etapa	Descrição	Entrega
Etapa 1	Definição da temática, dataset, escopo e documento inicial	04/06/2025
Etapa 2	Resultados preliminares (PoC), ajuste do pipeline, documentação da metodologia e referencial teórico	02/08/2025
Etapa 3	Otimização do motor de recomendação e documentação da metodologia	29/10/2025
Etapa 4	Resultados finais, interface gráfica, conclusão e gravação da apresentação	19/11/2025

8. Repositório no GitHub

O código-fonte do pipeline de ciência de dados, incluindo os scripts de Análise Exploratória, Pré-processamento e Treinamento da PoC do motor de recomendação, além dos arquivos da interface gráfica em CustomTkinter, está versionado no GitHub oficial do grupo.

Repositório: [GitHub | Projeto Aplicado III]

9. Referências

- LOPS, P.; DE GEMMIS, M.; SEMERARO, G. Content-based recommender systems: state of the art and trends. In: RICCI, F. et al. (Eds.). *Recommender Systems Handbook*. Springer, 2011.
- SCHEDL, M.; GÓMEZ, E.; URBANO, J. Music information retrieval: recent developments and applications. *Foundations and Trends in Information Retrieval*, 2014.
- RICCI, F.; ROKACH, L.; SHAPIRA, B. (Eds.). *Recommender Systems Handbook*. 2. ed. Springer, 2015.
- PANDYA, M. *Spotify Tracks Dataset*. Kaggle. Licença CC0. Disponível em: kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset.

